

# שיטות איטרטיביות בגברה ליניארית

**איטרציות פשוטות ליניאריות:** פתרון מערכת משוואות (בעזרת איטרציות ליניאריות במימד  $m$ )

$$x^{(n+1)} = Sx^{(n)} + b$$

$$x^{(1)} = Sx^{(0)} + b$$

$$x^{(2)} = Sx^{(1)} + b = S^2x^{(0)} + (S + I)b$$

$\vdots$

$$x^{(n)} = S^n x^{(0)} + (I + S + S^2 + \dots + S^{n-1})b$$

פונקציה ממשית  $\|A\| \equiv \text{norm}(A)$  נקראת נורמה של מטריצה  $A$  אם היא ומקיימת:

$$(1) \quad \|A\| \geq 0 \quad \text{לכל } A \quad (\|A\| = 0 \text{ אם ורק אם } A \equiv 0)$$

$$(2) \quad \|\alpha A\| = |\alpha| \|A\| \quad \text{לכל } \alpha \text{ ממשי (ליניאריות ביחס למכפלה בסקלר)}$$

$$(3) \quad \|A + B\| \leq \|A\| + \|B\| \quad (\text{אי-שוויון המשולש})$$

$$(4) \quad \|AB\| \leq \|A\| \|B\| \quad \text{לכל שני מטריצות רביעיות } A \text{ ו-} B.$$

ב-MATLAB משתמשים ב-  $\text{norm}(A, 1)$ ,  $\text{norm}(A, 2)$ ,  $\text{norm}(A, \text{inf})$

מתי  $x^{(n)}$  מתכנס לפתרון?  $\leftarrow$  כאשר  $\|S\| < 1$ . נניח ש-  $\|S\| = q < 1$

הוכחה:  $\|S^n\| \leq \|S\|^n = q^n$ .  $S^n x^{(0)} \rightarrow 0$  ולכן זניח.

$$\|I + S + S^2 + \dots + S^{n-1}\| \leq \|I\| + \|S\| + \|S^2\| + \dots + \|S^{n-1}\| \leq \|I\| + \|S\| + \|S\|^2 + \dots + \|S\|^{n-1} \leq \frac{1 - \|S\|^n}{1 - \|S\|}$$

הערה: כאשר דרשנו  $\|S\| < 1$ , כל נורמה בה  $\|S\| < 1$  יכולה לגרור התכנסות. יכול לקרות שבנורמה

מסוימת  $\|S\| < 1$  ואילו באחרת  $\|S\| > 1$ . במקרה זה מספיק למצוא נורמה אחת.

לדוגמא:  $Ax = b$

$$A = D + A'$$

$$D = \begin{pmatrix} a_{11} & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & a_{nn} \end{pmatrix}, \quad A' = \begin{pmatrix} 0 & & U \\ & \ddots & \\ L & & 0 \end{pmatrix}$$

(ב-MATLAB  $L = \text{tril}(A - D)$ ,  $U = \text{triu}(A - D)$ ,  $D = \text{diag}(\text{diag}(A))$ )

כעת, נוכל להציג את מערכת המשוואות באופן הבא:  $Dx = -A'x + b$

$$x = D^{-1}(b - A'x), \quad S = -D^{-1}(L + U)$$

שיטת יעקובי:

$$x^{(n+1)} = Sx^{(n)} + b' \xrightarrow{n \rightarrow \infty} x = Sx + b' \Leftrightarrow x = D^{-1}A'x + D^{-1}b$$

$$\text{JACOBI: } x^{(n+1)} = D^{-1} \cdot (b - (U + L)x^{(n)})$$

בפרט, השיטה היא מתכנסת עם מטריצה  $A$  מקיימת תנאי "האלכסון שולט":  $|a_{ii}| \geq \left| \sum_{i \neq j} a_{ij} \right|$

$$x = (D + L)^{-1}(b - Ux)$$

שיטת גאוס-זיידל:

$$x^{(n+1)} = Sx^{(n)} + b' \xrightarrow{n \rightarrow \infty} x = Sx + b', \quad S = -(D + U)^{-1}L$$

### מתי כדאי להשתמש בשיטת יעקובי, ומתי בשיטת הדירוג של גאוס?

השגיאה בשיטת הדירוג של גאוס עולה, בעוד בשיטת יעקובי היא יורדת. בגאוס יש  $\frac{n^3}{3}$  פעולות, לעומת עיקובי שמס. הפעולות תלוי בגודלה וסוגה של המטריצה. הגדרה:  $sparse matrix$  היא מטריצה שרוב האיברים בה הם אפסים. עבור מטריצות כאלו, חישוב בשיטת יעקובי הוא חסכוני ומהיר. האלגוריתם של  $Jacobi$  מתכנס כאשר:  $\|D^{-1}(L + U)\| \leq q < 1$ . ננסה לשפר את האלגוריתם של יעקובי באמצעות כתיבה שונה:

$$A = \{a_{ij}\}_{i,j=1}^m \quad Ax = b$$

$$\forall i = 1, \dots, n: \quad a_{ii}x_i + \sum_{j < i} a_{ij}x_j + \sum_{j > i} a_{ij}x_j = b_i$$

האלגוריתם של  $Gauss-Seidel$ :

$$x_i^{(n+1)} = \frac{-1}{a_{ii}} \left( \underbrace{\sum_{j < i} a_{ij}x_j^{(n+1)}}_L + \underbrace{\sum_{j > i} a_{ij}x_j^{(n)}}_U \right) + \frac{b_i}{a_{ii}}$$

אלגוריתם זה הוא מדויק יותר, כי משתמשים בערכי הווקטור שקיבלנו באותה האיטרציה. כלומר, משתמשים ב-  $x_j^{(n+1)}$  לחישוב  $x_i^{(n+1)}$

$$Ax = b \Rightarrow (D + L + U)x = b$$

$$(D + L)x = -Ux + b \Rightarrow x = (D + L)^{-1} \cdot (b - Ux)$$

$$x^{(n+1)} = (D + L)^{-1} (b - Ux^{(n)})$$

$$\text{GAUSS-SEIDEL: } x^{(n+1)} = (D + L)^{-1} \cdot (b - Ux^{(n)})$$

האלגוריתם של  $SOR$ : (קיצור של  $Successive Over Relaxation$ ) נכפיל ב- $w$  ונקבל:

$$w(D + L)x = w(b - Ux)$$

$$[D + (w - 1)D + wL]x = -wUx + wb$$

$$(D + wL)x = [-wU + (1 - w)D]x + wb$$

$$\Rightarrow x^{(n+1)} = (D + wL)^{-1} \cdot [(1 - w)D - wU] \cdot x^{(n)} + (D + wL)^{-1} wb$$

$$\text{SOR: } x^{(n+1)} = (D + wL)^{-1} \cdot [(1 - w)D - wU] \cdot x^{(n)} + (D + wL)^{-1} wb$$

קיבלנו  $SOR(w)$ . ע"י  $w$  אפשר להקטין את הנורמה של מטריצה  $S$ .  $\|S \cdot w\| \rightarrow \min$ , ואז מהירות ההתכנסות גבוהה הרבה יותר.

$SOR$  הוא האלגוריתם המדויק ביותר, אחריו  $Seidel$ , ו- $Jacoby$  הכי פחות מדויק.

## פתרון מערכת משוואות לא ליניארית

שיטה  $NEWTON-RAPHSON$  ( $N \sim R$ ) למערכת משוואות היא :

$$\begin{cases} f_1(x_1, x_2, \dots, x_m) = 0 \\ f_2(x_1, x_2, \dots, x_m) = 0 \\ \vdots \\ f_m(x_1, x_2, \dots, x_m) = 0 \end{cases}$$

$$N \sim R \quad x^{(n)} = (x_1^{(n)}, x_2^{(n)}, \dots, x_m^{(n)})$$

$$x^{(n+1)} = x^{(n)} - \left( f'(x^{(n)}) \right)^{-1} \cdot f(x^{(n)})$$

$$f(x_1, x_2, \dots, x_m) = 0 = \begin{cases} f_1(x_1, x_2, \dots, x_m) = 0 \\ f_2(x_1, x_2, \dots, x_m) = 0 \\ \vdots \\ f_m(x_1, x_2, \dots, x_m) = 0 \end{cases}$$

מטריצה יעקובי היא מטריצה שצורתה :

$$f' = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & & \vdots \\ \vdots & & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{pmatrix}$$

לדוגמא : ניקח את מערכת המשוואות הבאה :  $\text{אז} \cdot \begin{cases} f_1(x, y) : x^2 - y^2 - 3 = 0 \\ f_2(x, y) : 2xy - 2 = 0 \end{cases}$

$$J = f' = \begin{pmatrix} 2x & -2y \\ 2y & 2x \end{pmatrix}$$

היעקוביאן של מערכת המשוואות הוא  $|J| = 4(x^2 + y^2) \neq 0$

$$\Rightarrow (f')^{-1} = J^{-1} = \frac{1}{4(x^2 + y^2)} \begin{pmatrix} 2x & 2y \\ -2y & 2x \end{pmatrix}$$

$$\begin{pmatrix} x^{(n+1)} \\ y^{(n+1)} \end{pmatrix} = \begin{pmatrix} x^{(n)} \\ y^{(n)} \end{pmatrix} - \frac{1}{2(x_n^2 + y_n^2)} \begin{pmatrix} x_n & y_n \\ -y_n & x_n \end{pmatrix} \times \begin{pmatrix} x_n^2 - y_n^2 - 3 \\ 2x_n y_n - 2 \end{pmatrix}$$

אם האלגוריתם מתכנס אז :  $\boxed{f(x) = 0}$  \*  $x = x - f'(x)^{-1} \cdot f(x)$

הערה : אם האלגוריתם מתכנס אז הוא יתכנס בהכרח לנקודת שבת.

# אלגברה ליניארית נומרית

בעיות בהן אנו נתקלים :

$$1. \quad \sum_{j=1}^m a_{ij}x_j = b_i \quad i = 1, \dots, m. \quad Ax = b \quad \text{פתרון מערכת משוואות ליניאריות}$$

$$2. \quad \text{מציאת ערכים עצמיים} \quad Ax = \lambda x$$

$$3. \quad \text{פולינום אופייני:} \quad p(\lambda) = \det(A - \lambda \cdot I) = a_0\lambda^n + a_1\lambda^{n-1} + \dots$$

לדוגמא:  $Ax = b$ . איך נמדוד את השגיאה?

נניח ש-  $\tilde{b}$  היא השגיאה של  $b$ , ו-  $\tilde{x}$  היא השגיאה של  $x$ . כלומר,  $A\tilde{x} = \tilde{b}$

הקלט:  $b, \tilde{b}$  הפלט:  $x, \tilde{x}$

$$\|b\| = \|Ax\| \leq \|A\| \cdot \|x\|$$

$$\Rightarrow \|b - \tilde{b}\| = \|A(x - \tilde{x})\| \leq \|A\| \cdot \|x - \tilde{x}\|$$

$$x = A^{-1} \cdot b \Rightarrow \|x\| \leq \|A^{-1}\| \cdot \|b\|$$

$$\delta_x = \frac{\|x - \tilde{x}\|}{\|x\|} \leq k \cdot \delta_b = k \cdot \frac{\|b - \tilde{b}\|}{\|b\|}$$

$k$  משתנה ממערכת משוואות אחת לאחרת. כאשר  $k$  גדול (למשל  $k \approx 1000$ ) אז יש למטריצה תנאי חולה, או באנגלית: ill conditioning

$$\|x - \tilde{x}\| \leq \|A^{-1}\| \cdot \|b - \tilde{b}\|$$

$$\|x\| \geq \frac{\|b\|}{\|A\|} \Rightarrow \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}$$

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \frac{\|A^{-1}\| \cdot \|b - \tilde{b}\| \cdot \|A\|}{\|b\|}$$

סה"כ נקבל שה-  $k$  הוא:  $k = \|A\| \cdot \|A^{-1}\|$ .  $k$  יהיה מספר התנאי של מטריצה  $A$ .

ב-*Matlab* הפקודה תהיה  $\text{cond}(A, 1)$  (ה-1 מציין את מספר הנורמה של  $A$ ). אם נקבל מספר מאוד גדול, לא כדאי לחשב בשיטה נומרית שכן השגיאה תהיה גדולה מאוד. כעת, צריך למצוא מהו  $\|A\|$ :

$$1. \quad \rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \quad \text{רדיוס ספקטרלי אפשר להגדיר כ-}$$

$$2. \quad \|A\|_2 = \sqrt{\rho(A \cdot A^t)} \quad \text{"norm 2" (כמו הגדרתה לברירת המחדל ב-Matlab)}$$

$$\|L\| = \sup_{\|x\|_{B_1} \neq 0} \frac{\|Ax\|_{B_2}}{\|x\|_{B_1}} \quad \text{הגדרה: נגדיר } L: B_1 \rightarrow B_2 \text{ (מרחב איקלידי) ע"י:}$$

$$3. \quad \|A\|_\infty = \max_i \sum_j |a_{ij}| : \text{נורמת אינסוף}$$

$$\|Ax\|_\infty = \max_i \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_i \left( \sum_{j=1}^n |a_{ij}| \right) \cdot \max_j \{ |x_j| \} \leq k \|x\|_\infty : \text{נורמה של אופרטור}$$

$$A_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & \varepsilon \\ 0 & 0 & 1 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} = A_2 : \text{דוגמא}$$

$$A_1 - A_2 = \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & \varepsilon \\ 0 & 0 & 0 \end{pmatrix} : \text{לשניהם יש } k \text{ טוב}$$

$$|A - \lambda I| = (1 - \lambda)^3 = 0 \Rightarrow \lambda_{1,2,3} = 1 : \text{הערכים העצמיים של } A_1 \text{ ו- } A_2 \text{ הם}$$

$$\begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} : A_2 \text{ של וייע}$$

אבל יש רק שני הוקטורים העצמיים של  $A_1$ , ולכן ל-  $A_1, A_2$  לא יהיו את אותם הוקטורים העצמיים. קיבלנו שגיאה מעוד גדולה לחישוב ווקטורים עצמים!

ע"מ למצוא דטרמיננטה של מטריצה גדולה ניעזר בחילוף גאוס (וב-  $n^3/3 \sim$  פעולות אלמנטאריות).

זהו האלגוריתם הטוב ביותר לפתרון מבחינת כמות הפעולות הדרושות  $n^3/3 \sim$ .

כאשר משתמשים באלגוריתם  $x = A^{-1} \cdot b$  נקבל שמספר הפעולות  $2n^3/3 \sim$ .

## אלגוריתם גאוס

אלגוריתם גאוס נכשל כאשר הפיבוט (*Pivoting*) בעיזה שהוא שלב (  $a_{ii}^{(k)} = 0$  )

$$x_1 = 1 \Leftarrow x_2 = 1 \Leftarrow x_3 = 2 \Leftarrow \begin{pmatrix} -1 & 2 & 0 \\ 0 & 5 & -1 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix} \Leftarrow \begin{pmatrix} -1 & 2 & 0 \\ 0 & 0 & 1 \\ 0 & 5 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

השיטה המתוארת לעיל של החלפת רק שורות נקראת *partial pivoting*, ועם החלפת גם שורות וגם עמודות זוהי השיטה *pivoting*.

נקבל מטריצה אלכסונית עליונה:  $E_1 \cdot E_2 \cdot \dots \cdot E_n \cdot A = U$  (  $E_1, \dots, E_n$  הן מטריצות אלמנטאריות)

$$E_{ij} = i \quad \begin{pmatrix} 1 & 0 & \dots & 0 & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & \alpha & \dots & 1 & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 & 1 \end{pmatrix} \quad \begin{matrix} \\ \\ j \\ \\ i \end{matrix}$$

$$E_{ij} A \Rightarrow A \Leftrightarrow \text{row}_i + \alpha \text{row}_j \Rightarrow \text{row}_i$$

## פירוק LU $P \times A = L \times U$

כאשר  $U$  משולשית עליונה, ו- $L$  משולשית תחתונה.

$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \neq \begin{pmatrix} a_{11} & 0 \\ a_{21} & a_{22} \end{pmatrix} \times \begin{pmatrix} b_{11} & b_{12} \\ 0 & b_{22} \end{pmatrix} : \text{ללא המטריצה } P, \text{ הפירוק לא היה עובד. לדוגמא:}$$

הפקודה ב-Matlab:  $[L, U, P] = lu(A)$ . אלגוריתם זה דורש  $\sim n^3/3$  פעולות (זהה לגאוס).

**כיצד נפתור  $Ax = b$ ?**

$$PA = LU$$

$$PAx = Pb$$

$$LUx = Pb$$

$$\begin{cases} Ux = y & \sim \frac{n^2}{2} \\ Ly = Pb & \sim \frac{n^2}{2} \end{cases}$$

ואז מציאת מטריצה הפיכה לוקחת פחות פעולות (צריך בסה"כ למצוא הפיכה למטריצה משולשית תחתונה ועליונה).

## פירוק QR $A = QR$ כאשר $Q$ מטריצה אורתוגונאלית, ו- $R$ משולשית עליונה.

תזכורת: מטריצה אורתוגונאלית מקיימת:  $Q \times Q^t = I$

הפקודה ב-Matlab:  $[Q, R] = qr(A)$

**כיצד נפתור  $Ax = b$ ?**

$$(v_i, v_j) = \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

$$Ax = b \Rightarrow QRx = b$$

$$\begin{cases} Rx = y \\ Qy = b \Rightarrow y = Q^t Qy = Q^t b \end{cases}$$

כדי למצוא ערכים עצמיים נפעל באופן הבא:

$$A = [...]$$

for  $i = 1:10$  do

$$[Q, R] = qr(A);$$

$$A = R \times Q;$$

end

$Q$

$$Q = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} : Q \text{ תהיה מטריצה אלכסונית, שעל האלכסון יופיעו העי"ע.}$$

הליך גרהם-שמידט (Gram-Schmidt)

מטרתו: להפוך בסיס לבסיס אורתונורמאלי. ניקח ווקטור  $e_1$  בתור ווקטור בסיסי ראשון וננרמל אותו.

נגדיר  $\bar{e}_1 = \frac{e_1}{\|e_1\|}$ . בשלב שני ניקח שני ווקטורים  $e_1, e_2$  בנבנה ווקטור  $\bar{e}_2$  האנכי ל  $\bar{e}_1$  כפתרון של

משוואות:  $\| \bar{e}_2 \| = 1, (\bar{e}_2, \bar{e}_1) = 0$ . לדוגמה:

$$\bar{e}_2 = \lambda e_2 + \mu e_1$$

$$\bar{e}_3 = t e_3 + t_2 e_2 + t_3 e_1$$

אז  $\lambda(e_2, e_1) + \mu(e_1, e_1) = 0, \lambda(e_2, e_2) + \mu(e_1, e_2) = 1$  וכו'.

ע"י תהליך זה נקבל את  $Q$  מ- $A$ , והמטריצות שנעזרנו בהן מרכיבות את מטריצה  $R$ .

## פירוק SVD

נפרק את  $A$  באופן הבא:  $A = Q \times D \times S^T$  כאשר  $D$  היא אלכסונית, ו- $S$  היא אורתוגונאלית.

## שיטת Krylov למציאת פולינום אופייני למטריצות ריבועיות

לפי משפט קיילי המילטון, אם נציב את  $A$  במקום  $\lambda$  בפולינום האופייני, נקבל 0,  $(p(A) = 0)$ .

נבחר כל וקטור  $b$  שאינו ו"ע של  $A$ :

$$p(A) \cdot b = a_n \cdot \underbrace{A^n \cdot b}_{v_n} + a_{n-1} \cdot \underbrace{A^{n-1} \cdot b}_{v_{n-1}} + \dots + a_1 \cdot \underbrace{A \cdot b}_{v_1} + a_0 b = 0$$

$$a_n v_n + a_{n-1} v_{n-1} + \dots + a_1 v_1 = -a_0 b, \quad (a_0 = -1) \Rightarrow$$

$$B = (v_1, v_2, \dots, v_n) \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} = b$$

$$n^3 \sim A^2, \text{ פעולות, } n^3(k-1) \sim A^k, \text{ פעולות, } n^2 \sim v_{k+1} = Av_k, \text{ פעולות.}$$

## PRECONDITIONNING

תנאים התחלתיים, הנדרשים לפעמים לפני ביצוע האלגוריתם. לדוגמא: שגיאת תנאי.

$$\begin{pmatrix} 1 & \dots & \dots & 1 \\ -1 & \ddots & \mathbf{0} & \vdots \\ \vdots & \ddots & 1 & 1 \\ -1 & \dots & -1 & 1 \end{pmatrix} \xrightarrow{R_i = R_i + R_1} \begin{pmatrix} 1 & & & 1 \\ 0 & \ddots & & 2 \\ \vdots & -1 & \ddots & \\ \vdots & & \ddots & 1 \\ 0 & & & -1 & 2 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & 1 \\ & 2 & 2 \\ & & \ddots & \vdots \\ 0 & & & 2^{n-1} \end{pmatrix} \text{ : לדוגמא}$$

אם היינו עובדים עם נקודה צפה אז הייתה שגיאה גבוהה, ולכן טעינו בבחירת האלגוריתם. (אנו צריכים להשתמש בפעולות אלמנטאריות כך שהמספר הכי גבוה יהיה באלכסון) התנאי הזה נקראת תנאי האלכסון השולט, או באנגלית *diagonal dominant*.

## פירוק חולסקי (Cholesky)

אם  $A$  סימטרית וחיובית לחלוטין אז אפשר לפרק את  $A$  ל- $A = L \cdot L^T$ .  $L$  מטריצה משולשת תחתונה.

הפקודה ב-Matlab:  $L^T = \text{chol}(A)$